MINI-PROYECTO DE MACHINE LEARNING: INGRESOJUSTO
Evaluación de desempeño y análisis ético de un modelo de regresión logística para la preselección de crédito

Andrés Felipe Riaño Moreno
[Integrante 2]
[Integrante 3]

Noviembre 2026

Universidad de la Salle.
Ingeniería de Software.
[Nombre de la asignatura]

Introducción

Este informe acompaña el repositorio del proyecto y desarrolla los temas que no caben en el README: la justificación del modelo, la descripción del dataset, la interpretación de las métricas y de la matriz de confusión, el análisis ético y las recomendaciones. El código, el notebook ejecutado, las decisiones de arquitectura y el diagrama C4 están en la rama develop del repositorio:

https://github.com/And1224/proyectoFinal_IngresoJusto/tree/develop

El caso de uso es el de una fintech que quiere enviar ofertas de tarjeta de crédito solo a personas con ingresos suficientes, sin pedir soportes en la solicitud inicial. El modelo estima si una persona gana más de 50 000 USD al año. La pregunta del proyecto es doble: si el modelo funciona mejor que una regla trivial y si trata de forma equivalente a los distintos grupos de la población.

Selección del modelo

Se compararon cuatro candidatos con validación cruzada estratificada de cinco pliegues, usando solo el conjunto de entrenamiento y el umbral por defecto de 0,5 (Tabla 1).

Tabla 1
Comparación de modelos candidatos con validación cruzada de cinco pliegues

Modelo	Accuracy	F1	ROC-AUC
Línea base (clase mayoritaria)	0,761	0,000	0,500
Regresión logística	0,845	0,643	0,899
Árbol de decisión (profundidad 8)	0,855	0,648	0,903
KNN (k = 25)	0,847	0,663	0,898

Nota. Elaboración propia con scikit-learn (Pedregosa et al., 2011). La línea base predice siempre la clase mayoritaria.

Los tres modelos reales quedan a menos de 0,02 de F1 entre sí, así que el desempeño no decide la elección, Se eligió la **regresión logística** por tres razones, Primera, es transparente: cada coeficiente indica cuánto empuja una variable la decisión, y eso permite explicar a una persona por qué fue o no preseleccionada, Segunda, entrega probabilidades con las que se puede fijar el umbral según el costo de cada error, Tercera, a diferencia de KNN, no necesita guardar los datos personales de entrenamiento para predecir, El parámetro de regularización C se eligió por validación cruzada (C = 0,1) y el umbral de decisión, por el máximo F1 en el conjunto de validación (0,26).

Descripción del dataset

Se usó el dataset Adult del UCI Machine Learning Repository (Becker y Kohavi, 1996), un extracto del censo de Estados Unidos de 1994 con licencia CC BY 4,0, Tiene 48 842 registros, uno por persona; tras quitar 52 duplicados exactos quedan 48 790, El objetivo es la variable income, que vale 1 cuando la persona gana más de 50 000 USD al año, Solo el 23,9 % de los registros pertenece a esa clase, así que el dataset está desbalanceado.

Tabla 2

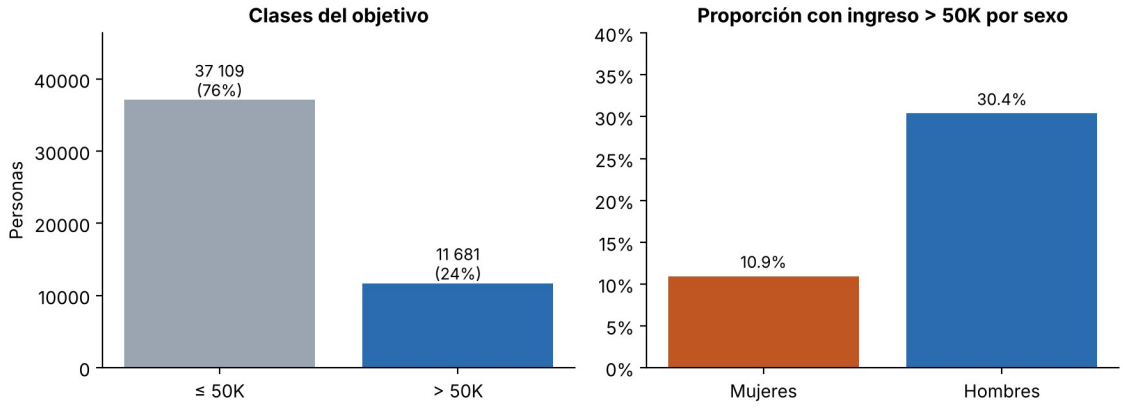
Variables del dataset y uso en el modelo

Variable	Tipo	Uso
age, education_num, hours_per_week	Numéricas	Entradas del modelo (imputadas y escaladas)
capital_gain, capital_loss	Numéricas asimétricas	Entradas, con transformación log1p
workclass, marital_status, occupation, relationship	Categóricas	Entradas, codificadas con one-hot
sex, race	Categóricas (atributos protegidos)	Excluidas del modelo; solo para auditar equidad
native_country	Categórica (atributo sensible)	Excluida
fnlwgt, education	Numérica y categórica	Excluidas: peso muestral y variable redundante
income	Objetivo binario	1 = más de 50 000 USD al año

Nota. Los valores faltantes (workclass 2 795, occupation 2 805 y native_country 856) se imputan con la categoría "Desconocido".

Figura 1

Distribución del objetivo y proporción de ingreso alto por sexo



Nota. Elaboración propia a partir de los 48 790 registros sin duplicados.

La Figura 1 adelanta el problema ético: en los datos, la proporción de hombres con ingreso alto (30,4 %) casi triplica la de las mujeres (10,9 %). Además, el 85,5 % de los registros corresponde a personas de raza blanca y el 66,8 % a hombres.

Métricas de evaluación

Los datos se partieron de forma estratificada en entrenamiento (70 %, 34 152 registros), validación (15 %, 7 319) y prueba (15 %, 7 319). El preprocesamiento se ajustó solo con entrenamiento, el umbral se eligió en validación y el conjunto de prueba se usó una sola vez. La Tabla 3 resume el resultado.

Tabla 3
Métricas en el conjunto de prueba

Métrica	Modelo (umbral 0,26)	Modelo (umbral 0,5)	Línea base
Accuracy	0,807	0,849	0,761
Precision	0,568	0,723	0,000
Recall	0,815	0,597	0,000
F1	0,669	0,654	0,000
ROC-AUC	0,902	0,902	0,500

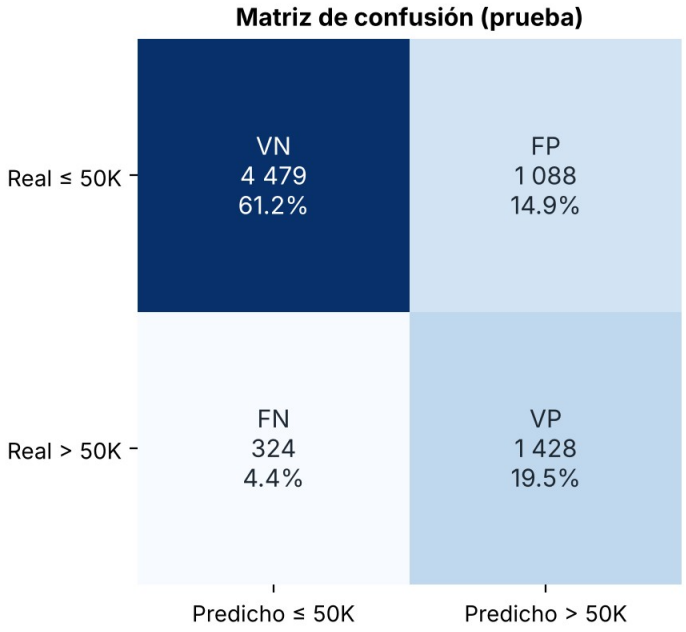
Nota. La línea base predice siempre "ingreso menor o igual a 50K".

- **Accuracy (0,807).** Es la proporción total de aciertos. Sola engaña: la línea base logra 0,761 sin detectar a una sola persona de ingreso alto, porque el 76 % de los registros son de la clase mayoritaria.
- **Precision (0,568).** De cada 100 personas que el modelo preselecciona, 57 tienen de verdad ingreso alto. Las otras 43 recibirían una oferta de crédito para la que no tienen ingresos suficientes.
- **Recall (0,815).** De cada 100 personas con ingreso alto, el modelo encuentra 82.
- **F1 (0,669).** Resume el equilibrio entre precision y recall; la línea base obtiene 0.
- **ROC-AUC (0,902).** Si se toma al azar una persona de ingreso alto y otra de ingreso bajo, el modelo le asigna mayor probabilidad a la primera el 90 % de las veces.

El umbral de 0,26 privilegia el recall: deja por fuera a menos personas que sí califican, a cambio de más falsos positivos. Con el umbral convencional de 0,5 la precision sube a 0,723, pero el recall cae a 0,597. La elección no es técnica sino de negocio: depende de qué error le cuesta más a la fintech y a las personas.

Matriz de confusión

Figura 2
Matriz de confusión del modelo en el conjunto de prueba



Nota. VN: verdaderos negativos; FP: falsos positivos; FN: falsos negativos; VP: verdaderos positivos.

Tabla 4
Interpretación de cada celda de la matriz de confusión

Celda	Cantidad	Significado en el caso de uso
Verdaderos positivos (VP)	1 428	Personas con ingreso alto correctamente preseleccionadas
Falsos positivos (FP)	1 088	Personas con ingreso bajo a quienes se les ofrecería crédito: riesgo de sobreendeudamiento
Verdaderos negativos (VN)	4 479	Personas con ingreso bajo correctamente descartadas
Falsos negativos (FN)	324	Personas con ingreso alto que pierden la oferta aunque califican

Análisis ético

Sesgos del dataset y del modelo

El dataset arrastra un sesgo histórico: refleja la brecha salarial de 1994 entre hombres y mujeres y entre grupos raciales. Un modelo entrenado con esos datos aprende la brecha y la

aplica a decisiones nuevas. La Tabla 5 muestra cómo se comporta el modelo con cada grupo en el conjunto de prueba.

Tabla 5

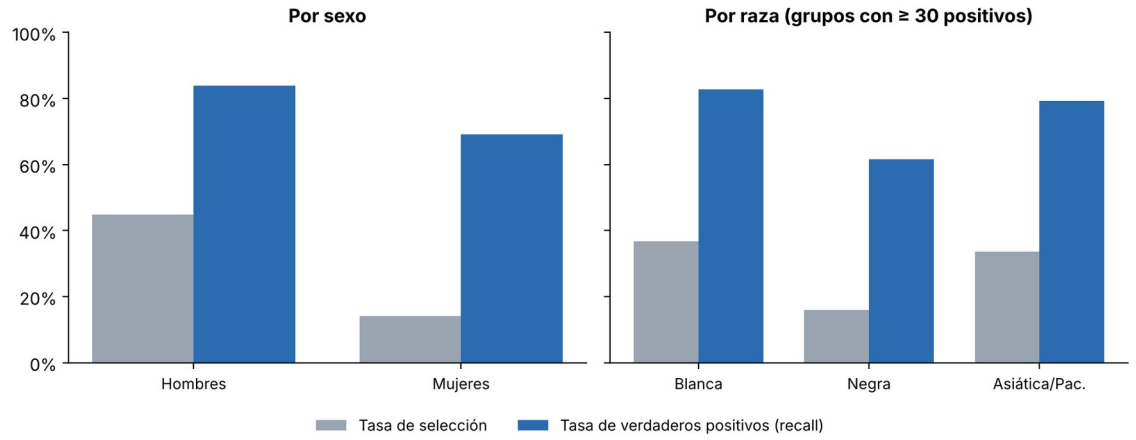
Desempeño del modelo por grupo en el conjunto de prueba

Grupo	n	Tasa real de ingreso alto	Tasa de selección	Recall	Falsos positivos
Hombres	4 823	30,5 %	44,8 %	83,9 %	27,7 %
Mujeres	2 496	11,3 %	14,1 %	69,1 %	7,1 %
Raza blanca	6 264	25,5 %	36,8 %	82,8 %	21,0 %
Raza negra	689	12,5 %	16,0 %	61,6 %	9,5 %
Asiática o de islas del Pacífico	232	22,8 %	33,6 %	79,2 %	20,1 %

Nota. Las personas amerindias (71) y de "otra" raza (63) no se evalúan por tener menos de 30 casos positivos.

Figura 3

Tasa de selección y recall por sexo y por raza



El hallazgo central es la brecha de recall: una mujer que sí gana más de 50 000 USD tiene un 31 % de probabilidad de quedar por fuera, frente a un 16 % de un hombre en la misma situación. Entre personas de raza negra y blanca la diferencia de recall es de 21 puntos. Los grupos pequeños, como las personas amerindias, ni siquiera tienen datos suficientes para medir cómo los trata el modelo, lo que también es un sesgo de representación.

Quitar el sexo y la raza de las entradas no elimina el problema. La variable relationship funciona como proxy: el valor "Husband" corresponde a un hombre en el 99,99 % de los casos y "Wife" a una mujer en el 99,87 %. El equipo hizo un experimento para medir el efecto de incluir los atributos protegidos (Tabla 6).

Tabla 6
Efecto de incluir sexo y raza como entradas del modelo

Indicador	Sin sexo ni raza (modelo elegido)	Con sexo y raza
F1	0,669	0,682
Diferencia de recall entre sexos	0,147	0,230
Razón de impacto dispar entre sexos	0,315	0,259

Incluir los atributos mejora el F1 en apenas 0,01, pero aumenta la brecha de recall de 0,15 a 0,23. Por eso el modelo final los excluye, sabiendo que esa medida reduce el sesgo sin eliminarlo.

Equidad

El equipo midió dos criterios de equidad. La razón de impacto dispar compara la proporción de personas seleccionadas en cada grupo: entre mujeres y hombres es 0,315, muy por debajo del 0,8 de la regla de los cuatro quintos. Sin embargo, buena parte de esa diferencia viene de los datos: incluso un modelo perfecto tendría una razón cercana a 0,37, porque esa es la relación entre las tasas reales de ingreso alto. Exigir la misma tasa de selección obligaría a sacrificar exactitud, y la literatura muestra que no se pueden cumplir a la vez todos los criterios de equidad cuando los grupos tienen tasas base distintas (Barocas et al., 2023).

Por eso el criterio más pertinente para este caso es la igualdad de oportunidades: quienes sí cumplen la condición deberían tener la misma probabilidad de ser preseleccionados, sin importar su grupo (Hardt et al., 2016). El modelo tampoco lo cumple: la diferencia de recall entre sexos es 0,147, frente a un máximo aceptable de 0,10. En cambio, la precision es parecida entre hombres (57,0 %) y mujeres (55,2 %): cuando el modelo preselecciona a alguien, acierta casi igual en ambos grupos.

Privacidad y uso responsable de los datos

El dataset no contiene nombres ni documentos, pero la combinación de edad, ocupación, raza y país de origen puede reidentificar a personas de grupos pequeños. En Colombia, el origen racial o étnico es un dato sensible según la Ley 1581 de 2012, cuyo tratamiento requiere autorización explícita, y el uso de información para decisiones de crédito está regulado por la Ley 1266 de 2008. Un uso responsable implica recolectar solo las variables necesarias, no guardar los atributos protegidos junto con las predicciones salvo para auditoría controlada, obtener el consentimiento de los solicitantes y conservar los datos solo el tiempo necesario.

Impacto social

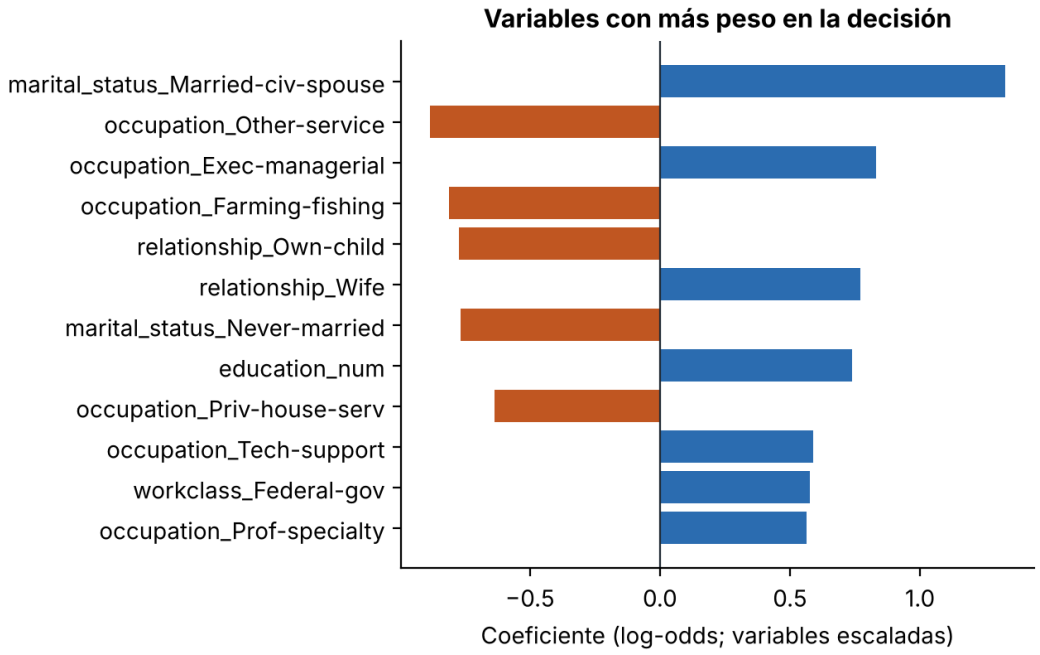
Los dos tipos de error afectan a personas reales. Un falso positivo puede llevar a ofrecer crédito a alguien sin capacidad de pago y contribuir al sobreendeudamiento. Un falso negativo le niega una oportunidad financiera a quien sí califica, y el modelo comete más falsos negativos con mujeres y con personas de raza negra. Si las decisiones del modelo se usaran después para reentrenarlo, la exclusión se reforzaría sola: quienes no reciben crédito tampoco generan historial que demuestre que podían pagarlo.

Justicia y transparencia en la toma de decisiones

La regresión logística permite explicar cada resultado: la Figura 4 muestra las variables con más peso. Estar casado y tener cargos directivos o más años de educación empujan hacia la preselección; ocupaciones de servicios o de trabajo en el campo empujan en contra. Esa transparencia hace posible que una persona entienda y controvierta la decisión, algo que exige la Recomendación sobre la ética de la inteligencia artificial de la UNESCO (2021). Para que el proceso sea justo, la decisión final debe tomarla un analista, con la posibilidad de que el solicitante aporte soportes de ingreso, y el modelo debería publicarse con una ficha que documente su uso previsto, sus métricas por grupo y sus límites (Mitchell et al., 2019).

Figura 4

Variables con más peso en las decisiones del modelo



Nota. Coeficientes de la regresión logística sobre variables escaladas. Barras azules: aumentan la probabilidad de ingreso alto; naranjas: la disminuyen.

Conclusiones técnicas

El modelo funciona bien desde el punto de vista técnico. Supera ampliamente la línea base (F1 de 0,669 frente a 0 y ROC-AUC de 0,902 frente a 0,5), cumple los criterios de aceptación técnicos y no muestra sobreajuste: el ROC-AUC es similar en validación (0,891) y en prueba (0,902). Con el umbral de 0,26 detecta el 82 % de las personas con ingreso alto.

Desde el punto de vista ético no está listo para decidir solo. No cumple la igualdad de oportunidades entre sexos ni la regla de los cuatro quintos, conserva sesgo a través de variables proxy y fue entrenado con datos de otro país y de hace más de treinta años. Por eso se acepta únicamente como prototipo de apoyo a la decisión humana.

Recomendaciones

1. Usar el modelo solo como apoyo: un analista revisa los casos, en especial los rechazados, y el solicitante puede aportar soportes de ingreso.
2. Aplicar técnicas de mitigación, como el repesado de muestras o umbrales que igualen el recall entre grupos, y volver a medir los criterios de equidad.
3. Reentrenar con datos colombianos recientes, recolectados con consentimiento y bajo la Ley 1581 de 2012.
4. Evaluar el efecto de quitar las variables proxy (relationship y marital_status) sobre el desempeño y la equidad.
5. Fijar el umbral con el negocio a partir del costo de cada tipo de error, en lugar de solo maximizar F1.
6. Auditar el desempeño por grupo en cada nueva versión del modelo y publicar sus resultados en una ficha del modelo.

Referencias

Barocas, S., Hardt, M. y Narayanan, A. (2023). *Fairness and machine learning: Limitations and opportunities*. MIT Press. https://fairmlbook.org

Becker, B. y Kohavi, R. (1996). *Adult* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5XW20

Congreso de Colombia. (2008). *Ley Estatutaria 1266 de 2008*. Por la cual se dictan las disposiciones generales del hábeas data y se regula el manejo de la información contenida en bases de datos personales, en especial la financiera.

Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012*. Por la cual se dictan disposiciones generales para la protección de datos personales.

Hardt, M., Price, E. y Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems, 29*, 3315–3323.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D. y Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

UNESCO. (2021). *Recomendación sobre la ética de la inteligencia artificial*. https://unesdoc.unesco.org/ark:/48223/pf0000380455_spa